Патентный анализ: гибридная система поиска для ИИ

Учебное описание изобретения и анализ патентоспособных признаков

Имя файла	ai_patent_2024.pdf
Название	Патентный анализ: гибридная система поиска для ИИ
Дата	2024-06-15
Тип документа	патент
Основная тема	Гипотетическая патентная концепция гибридного RAG с цитированием и контролем доступа

Ниже приведён синтетический патентный документ, созданный для тестирования поиска по патентным материалам. Номера заявки, формулы и технические параметры являются вымышленными.

1. Библиографические сведения

Показатель	Значение
Условный номер заявки	RU-AI-2024-0615-HRAG
Дата приоритета	2024-06-15
Заявитель	АО "Технологии знаний" (вымышленная организация)
Область техники	информационный поиск и генеративный искусственный интеллект
Название изобретения	Способ формирования проверяемого ответа на основе гибридного поиска по документам

2. Область техники

Изобретение относится к системам обработки естественного языка, информационному поиску и генерации текста с использованием больших языковых моделей. В частности, способ предназначен для формирования ответа на вопрос пользователя на основании электронных документов с сохранением ссылки на конкретный источник.

Техническое решение может применяться в корпоративных базах знаний, научно-технических архивах, патентных коллекциях, регламентах и закрытых информационных системах.

3. Предшествующий уровень техники

Известны системы семантического поиска, в которых запрос преобразуется в вектор и сравнивается с векторами документов. Их недостатком является пониженная точность при поиске точных артикулов, кодов, редких обозначений и дат. Известны также лексические методы типа BM25,

которые хорошо обрабатывают совпадения терминов, но хуже находят смысловые переформулировки.

Отдельной проблемой генеративных систем является формирование утверждений, отсутствующих в источнике. Даже если найден релевантный документ, языковая модель может добавить правдоподобную, но неподтверждённую деталь. Поэтому требуется архитектура, связывающая retrieval, генерацию и проверку цитаты.

4. Сущность изобретения

Предлагаемый способ выполняет параллельный семантический и лексический поиск. Результаты объединяются с помощью рангового алгоритма, после чего выполняется повторное ранжирование кандидатов. Перед передачей фрагмента в генеративную модель применяется фильтр прав доступа пользователя.

Каждый фрагмент содержит метаданные filename, title, date, document_type, page_number и access_group. Генеративная модель получает идентификаторы фрагментов и обязана сформировать ответ вместе со списком идентификаторов, поддерживающих каждое существенное утверждение.

Показатель	Значение
Размер текстового фрагмента	условно 600 токенов
Перекрытие соседних фрагментов	80 токенов
Dense кандидаты	20
BM25 кандидаты	20
После RRF	12
После reranking	4
Порог минимальной релевантности	0,62 по нормированной шкале

5. Формула изобретения

Независимый пункт формулы описывает способ компьютерной обработки запроса пользователя. Зависимые пункты уточняют метаданные, схему контроля доступа, проверку цитат и режим отказа от ответа.

- 1. Получение пользовательского запроса и идентификатора роли пользователя.
- 2. Формирование семантического представления запроса и лексического представления запроса.
- 3. Параллельный поиск по векторному индексу и инвертированному индексу.
- 4. Объединение рангов результатов по Reciprocal Rank Fusion с постоянной k = 60.
- 5. Исключение документов, не разрешённых текущей роли.
- 6. Повторное ранжирование разрешённых фрагментов моделью cross-encoder.
- 7. Генерация ответа только по четырём верхним фрагментам.
- 8. Проверка того, что каждое ключевое утверждение связано хотя бы с одним идентификатором источника.
- 9. Формирование отказа, если доказательств недостаточно.

6. Технический результат

Техническим результатом считается повышение воспроизводимости и проверяемости ответа при одновременном улучшении полноты поиска для запросов, содержащих как смысловые формулировки, так и точные обозначения. Дополнительный результат - предотвращение передачи в контекст фрагментов, к которым пользователь не имеет доступа.

В условном эксперименте на 120 вопросах гибридная схема получила Recall@4 = 0,96 против 0,89 для dense-only и 0,91 для BM25-only. Доля ответов с корректной ссылкой на источник составила 97%. Эти значения являются частью синтетического примера.

7. Пример реализации

Пользователь задаёт вопрос: "Какой порог температуры указан для модуля XQ-17?" Семантический поиск находит общий раздел о тепловом режиме, а BM25 находит техническую страницу с точным кодом XQ-17. После объединения и reranking техническая страница занимает первое место. Генеративная модель отвечает: "Порог предупреждения составляет 78 °C" и прикладывает ссылку на конкретный фрагмент.

Если роль пользователя не имеет доступа к документу с XQ-17, этот фрагмент удаляется до генерации. Система не должна использовать скрытый документ даже если он имеет максимальную релевантность.

8. Отличительные признаки

- Гибридный retrieval выполняется до контроля доступа, но перед генерацией применяется обязательная фильтрация по ролям.
- Цитата является частью структурированного результата, а не постобработкой свободного текста.
- Система умеет отказаться от ответа по порогу доказательности.
- Дата документа учитывается как метаданный фильтр для запросов "по состоянию на дату".