Отчёт об искусственном интеллекте - 2024

Состояние технологий, практические сценарии и контроль качества на начало 2024 года

Имя файла	ai_report_2024.pdf
Название	Отчёт об искусственном интеллекте - 2024
Дата	2024-03-10
Тип документа	отчёт
Основная тема	Генеративный ИИ, RAG, малые модели, корпоративное внедрение и управление рисками

Документ описывает условное состояние рынка искусственного интеллекта в 2024 году. Все количественные показатели внутри документа созданы специально для тестового RAG-корпуса и не должны интерпретироваться как официальная статистика.

1. Резюме

В 2024 году корпоративный искусственный интеллект смещается от демонстрационных чат-ботов к прикладным системам, встроенным в рабочие процессы. Наибольшее внимание получают генеративные модели, поиск по внутренним знаниям, автоматизация обработки документов и инструменты помощи специалистам. Главной задачей становится не максимальный размер модели, а управляемое качество ответа, стоимость эксплуатации и возможность проверить источник.

Для закрытых корпоративных данных наиболее практичной архитектурой считается Retrieval-Augmented Generation (RAG). Она сочетает языковую модель с поиском по документам и позволяет формировать ответ на основе найденных фрагментов. В отличие от простого запроса к модели, RAG даёт возможность показывать ссылки на источники и ограничивать знания набором разрешённых документов.

Показатель	Значение
Доля пилотных AI-проектов, использующих RAG	условно 46%
Типичный размер внутреннего корпуса	от 10 тыс. до 3 млн текстовых фрагментов
Целевой порог точности цитирования	не ниже 95% корректных ссылок
Средняя целевая задержка для корпоративного ассистента	до 4 секунд на ответ
Основной риск	правдоподобный ответ без подтверждения источником

2. Генеративный ИИ и корпоративные сценарии

Генеративные модели применяются для суммаризации, подготовки черновиков, классификации обращений, извлечения фактов и диалогового доступа к базам знаний. В промышленности востребованы ассистенты для инженеров и сервисных служб, а в финансовом секторе - поиск по внутренним политикам и нормативным документам.

Организации постепенно разделяют задачи на две группы. Для открытых и некритичных сценариев допускается использование внешних облачных API. Для конфиденциальных данных чаще рассматриваются локально развёрнутые модели или защищённый частный контур. Это повышает требования к инфраструктуре, мониторингу и управлению версиями моделей.

- Суммаризация длинных документов с указанием исходных разделов.
- Поиск ответов в регламентах, технических руководствах и патентных коллекциях.
- Извлечение сущностей: организации, даты, оборудование, номера документов и технологические параметры.
- Классификация входящих текстов по тематике и приоритету.
- Подготовка черновиков ответов, которые затем проверяет сотрудник.

3. Архитектура RAG

Базовый RAG-конвейер включает загрузку документа, очистку текста, разбиение на фрагменты, построение эмбеддингов, индексирование и поиск релевантных фрагментов. После поиска контекст передаётся генеративной модели вместе с вопросом пользователя. Ответ должен содержать только факты, поддерживаемые контекстом.

В 2024 году возрастает интерес к гибридному поиску. Семантический поиск хорошо находит близкий смысл, но может пропустить точные обозначения, номера моделей и аббревиатуры. Лексический поиск BM25, напротив, силён на редких терминах. Комбинация результатов через Reciprocal Rank Fusion (RRF) уменьшает вероятность пропуска релевантного документа.

3.1 Рекомендуемые этапы

- Нормализация и удаление служебного шума из PDF, DOCX и HTML.
- Chunking размером 400-900 токенов с небольшим перекрытием.
- Сохранение метаданных: filename, title, date, document_type и номер страницы.
- Одновременный dense и sparse retrieval.
- Reranking верхних кандидатов перед генерацией ответа.
- Формирование цитат на уровне конкретного фрагмента и страницы.

3.2 Метрики качества

Для retrieval следует отдельно измерять Hit Rate, Recall@k и MRR. Для ответа важны faithfulness, context precision, полнота цитирования и доля отказов при недостатке доказательств. Высокая языковая плавность не считается достаточным показателем качества.

4. Малые модели и локальный контур

Малые языковые модели становятся привлекательными для задач, где важнее предсказуемая стоимость и конфиденциальность, чем универсальность. В закрытом контуре модель может работать рядом с векторным индексом и внутренним API. При этом качество RAG часто сильнее зависит от качества retrieval и структуры документов, чем от небольшого прироста параметров генеративной модели.

Для локального развёртывания критичны квантование, управление памятью GPU, пакетная обработка запросов и наблюдаемость. Команда должна фиксировать версию модели, шаблон промпта, параметры поиска и набор документов, использованный при ответе.

5. Риски и меры контроля

- Галлюцинации: модель добавляет факт, которого нет в retrieved context. Мера - строгий системный промпт и проверка faithfulness.
- Устаревшие сведения: новый документ не попал в индекс. Мера - автоматическая переиндексация и контроль даты источника.
- Нарушение прав доступа: пользователь получает фрагмент чужого документа. Мера - фильтрация retrieval по ролям до передачи контекста модели.
- Prompt injection в документе: вредоносная инструкция попадает в контекст. Мера - отделение данных от инструкций и фильтрация подозрительных шаблонов.
- Неверная цитата: ссылка ведёт на нерелевантный фрагмент. Мера - отдельная проверка соответствия ответа и источника.

6. Выводы

В 2024 году основная ценность корпоративного ИИ находится на пересечении языковых моделей и управляемых данных. Для продуктивного внедрения необходимы retrieval, цитирование, контроль доступа, наблюдаемость и набор воспроизводимых тестов. RAG рассматривается не как простой поиск с чат-интерфейсом, а как система принятия ответа на основе доказательств.